

CoT (Chain of Thought) 实验测试报告书

报告概述

实验名称: Chain of Thought 提示技术对大语言模型推理能力的影响研究

实验日期: 2026年6月8日

实验者: AI Chat Tool 项目组

报告版本: 1.0

报告日期: 2026年6月12日

执行摘要

核心发现

通过21道题目的对照实验, 本研究验证了 **Chain of Thought (CoT)** 提示技术对大语言模型推理能力的显著提升作用:

指标	无CoT	有CoT	提升幅度
准确率	57.14%	90.48%	+33.33%
正确题数	12/21	19/21	+7题
总Token消耗	2,996	14,272	+376.37%
平均每题Token	143	680	+375.9%

关键结论

- ✅ CoT技术在复杂推理任务中具有显著优势
- ✅ 准确率提升58.3% (相对提升)
- ✅ Token成本增加约3.8倍, 但换来准确率大幅提升
- ✅ 在数学计算和逻辑推理类题目中效果最为明显

实验背景

Chain of Thought 技术简介

Chain of Thought (CoT) 是一种提示工程技术，通过要求模型展示中间推理步骤，显著提升其在复杂推理任务上的表现。

核心原理：

- 要求模型逐步展示推理过程
- 显式化隐含的思维链
- 提供更多推理路径的监督信号

典型触发词：

- "Let's think step by step" (让我们一步步思考)
- "请一步步详细思考，展示你的完整推理过程"

实验动机

1. **理论验证**：在实际应用场景中验证CoT技术的有效性
2. **性能评估**：量化CoT对准确率和Token成本的影响
3. **实践指导**：为项目中的thinking mode功能提供数据支持

实验设计

实验配置

实验环境：

模型：qwen-turbo（阿里云通义千问）

温度参数：0.0（确保可重复性）

API提供商：阿里云Dashscope

实验日期：2026-06-08

输出长度控制：

- 无CoT模式：max_tokens = 100（强制简洁回答）
- 有CoT模式：max_tokens = 2000（允许详细推理）

CoT提示词：

- 请一步步详细思考，展示你的完整推理过程。要求：
1. 分步骤分析问题
 2. 说明每个步骤的理由
 3. 最后给出明确的答案

测试题库设计

实验共使用 **21道题目**，分为3个类别：

1. 数学计算类（7题）

测试目标：验证多步算术推理能力

题目ID	题目描述	难度	知识点
1	小明弹珠问题（四步运算）	中	多步算术
2	电影院座位问题（除法运算）	中	基础除法
3	水果购买问题（多步计算）	中	加减乘除
4	逆运算问题（方程求解）	高	逆运算思维
5	工厂生产问题（倍数计算）	中	倍数关系
6	行程问题（速度时间关系）	高	方程思维
7	水池进水问题（工作效率）	高	分数运算

2. 逻辑推理类（7题）

测试目标：验证逻辑演绎和推理能力

题目ID	题目描述	难度	知识点
8	三盒子标签问题	高	逻辑演绎
9	大小排序问题	低	简单排序

题目ID	题目描述	难度	知识点
10	三段论问题	中	逻辑传递
11	家庭成员推理	高	信息整合
12	星期计算问题	中	周期计算
13	骑士无赖问题	高	逻辑假设
14	囚犯盒子问题	高	排列组合

3. 常识推理类（7题）

测试目标：验证常识应用和因果推理能力

题目ID	题目描述	难度	知识点
15	热水冰箱问题	中	热力学
16	镜子成像问题	中	光学原理
17	闪电雷声问题	低	物理常识
18	植物黑暗问题	中	生物常识
19	衣服颜色问题	中	光学吸收
20	密封房间蜡烛问题	高	化学知识
21	高原沸点问题	高	物理应用

实验变量

自变量：CoT模式（开/关）

因变量：

- 答案正确性（主要指标）
- Token使用量（成本指标）
- 推理过程质量（质性指标）


控制变量：

- 模型选择（qwen-turbo）
- 温度参数（0.0）

- 测试题目（21道固定题目）
- API配置（Dashscope）

实验结果

整体性能统计



详细统计表

统计指标	无CoT	有CoT	差异
总题目数	21	21	-
答对题数	12	19	+7
答错题数	9	2	-7
准确率	57.14%	90.48%	+33.33%
总Token数	2,996	14,272	+11,276
平均每题Token	143	680	+537
Token增加比例	100%	376.37%	+276.37%

分类性能对比

准确率对比（按类别）

题目类别	题目数量	无CoT准确率	有CoT准确率	提升幅度
数学计算	7	71.43% (5/7)	85.71% (6/7)	+14.28%
逻辑推理	7	57.14% (4/7)	85.71% (6/7)	+28.57%
常识推理	7	42.86% (3/7)	100.00% (7/7)	+57.14%

关键发现：

- 常识推理类提升最为显著（+57.14%）
- 逻辑推理类次之（+28.57%）
- 数学计算类提升相对较小（+14.28%）

Token消耗对比（按类别）

题目类别	无CoT平均Token	有CoT平均Token	增长倍数
数学计算	146	566	3.88x
逻辑推理	155	671	4.33x
常识推理	127	802	6.31x

关键发现：

- 常识推理类Token增长最大（6.31倍）
- 逻辑推理类次之（4.33倍）
- 数学计算类增长相对较小（3.88倍）

详细案例分析

案例一：数学计算类典型成功案例

题目（ID: 1）：

小明有15个弹珠，给了小红3个，又买了8个，然后掉了2个。请问小明现在有多少个弹珠？

无CoT回答 (✗ 错误)

我们来一步一步来计算小明现在有多少个弹珠：

1. 小明最开始有 **15** 个弹珠。
2. 给了小红 **3** 个，剩下：
 $15 - 3 = 12$ 个
3. 然后买了 **8** 个，现在有：
 $12 + 8 = 20$ 个
4. 最后掉了

Token使用：146

问题：输出被截断，未完成计算

有CoT回答 (✅ 正确)

我们来一步一步地分析这个问题，确保每一步都清晰明了。

第一步：小明最开始有多少个弹珠？

题目中说："小明有15个弹珠。"

- **理由**：这是问题的起点，是已知条件。
- **当前数量**：15个弹珠

第二步：小明给了小红3个弹珠

小明给了小红3个弹珠，意味着他手中的弹珠数量减少了。

- **理由**：给出去的弹珠不再属于小明，所以要从总数中减去。
- **计算**： $15 - 3 = 12$
- **当前数量**：12个弹珠

第三步：小明又买了8个弹珠

小明买了新的弹珠，说明他的弹珠数量增加了。

- **理由**：新买的弹珠是小明拥有的，应该加到现有数量上。
- **计算**： $12 + 8 = 20$
- **当前数量**：20个弹珠

第四步：小明掉了2个弹珠

掉了一个弹珠，意味着他失去了这2个弹珠。

- **理由**：掉的弹珠不再属于小明，需要从总数中减去。
- **计算**： $20 - 2 = 18$
- **当前数量**：18个弹珠

最终答案：

小明现在有 **18个弹珠**。

Token使用：408

优势：

- 步骤清晰完整
- 每步都有明确理由
- 最终答案正确

案例二：逻辑推理类典型成功案例

题目 (ID: 8):

有三个盒子，一个装红球，一个装蓝球，一个装红蓝混合。三个盒子标签全贴错了。如果从标签为'红球'的盒子中取出一个球是红色，问这个盒子实际装什么？其他两个盒子各装什么？

无CoT回答 (✅ 正确但不够详细)

我们来一步步分析这个问题。

- ### 已知条件：
- 有三个盒子，分别贴着标签：
 - **盒子A**：红球
 - **盒子B**：蓝球
 - **盒子C**：红蓝混合
 - 但**所有标签都贴错了**（即每个盒子的实际内容与标签不符）。
 - 然后从标签为"红球"的盒子中取出一个球是**红色**。

Token使用：170

问题：推理过程不够详细，结论缺乏充分论证

有CoT回答 (✅ 正确且详细)

我们来一步一步地分析这个问题。

题目回顾:

有三个盒子，分别标为：

- 盒子A：标签是"红球"
- 盒子B：标签是"蓝球"
- 盒子C：标签是"红蓝混合"

但**所有标签都贴错了**。

然后从标签为"红球"的盒子（盒子A）中取出一个球，发现是**红色**。

第一步：明确已知条件

1. 三个盒子的标签全贴错了。
2. 从标签为"红球"的盒子中取出一个球是红色。

第二步：分析标签错误的含义

由于所有标签都贴错了，我们可以列出可能的排列组合，但更有效的方法是通过逻辑推理。

第三步：从盒子A中取出一个红球

我们从标签为"红球"的盒子（盒子A）中取出一个球，结果是**红色**。

根据前面的条件，盒子A**不能是红球**，但我们现在却从中取出了一个红球。这说明什么呢？

这说明：虽然盒子A的标签是"红球"，但它实际上**不是红球**，但里面却有红球。那它只能是**红蓝混合**。

第四步：确定盒子A的内容

结论：盒子A实际装的是**红蓝混合**。

第五步：推断其他两个盒子的内容

现在我们知道：

- 盒子A：红蓝混合（标签是"红球"，但实际不是红球）
- 所以剩下的两个盒子（B和C）分别是"红球"和"蓝球"，但它们的标签也都是错的。

最终结论:

- **盒子A（标签为"红球"）** 实际装的是 **红蓝混合**
- **盒子B（标签为"蓝球"）** 实际装的是 **红球**
- **盒子C（标签为"红蓝混合"）** 实际装的是 **蓝球**

Token使用：1,247

优势：

- 逐步假设验证
- 逻辑链条完整
- 结论有充分依据

案例三：常识推理类典型成功案例

题目 (ID: 20)：

在一个完全密封的房间里点燃蜡烛，蜡烛最终会熄灭。这是为什么？需要什么条件才能持续燃烧？

无CoT回答 (✅ 正确但简洁)

在一个完全密封的房间里点燃蜡烛，蜡烛最终会熄灭，这是因为燃烧需要三个基本条件：可燃物、助燃物

一、为什么蜡烛会熄灭？

1. 氧气耗尽

蜡烛燃烧是一个氧化反应，需要氧气

Token使用：138

问题：解释不够深入，缺乏详细说明

有CoT回答 (✅ 正确且详细)

我们来一步步分析"在一个完全密封的房间里点燃蜡烛，蜡烛最终会熄灭"的原因。

第一步：理解燃烧的基本原理

燃烧是一种化学反应，通常是指可燃物（如蜡烛中的石蜡）与氧气发生氧化反应，释放出热量和光。

这个过程需要三个基本要素：

1. **可燃物**（如蜡烛的蜡）
2. **助燃物**（通常是氧气）
3. **点火源**（如火焰或火花）

第二步：分析完全密封房间的环境

"完全密封"意味着房间内的空气无法与外界交换。也就是说：

- 空气不会进入房间
- 空气也不会从房间中逸出

因此，房间内原有的空气量是固定的。

第三步：蜡烛燃烧时对氧气的消耗

当蜡烛被点燃后，它会不断消耗氧气进行燃烧。随着燃烧的进行，房间内的氧气逐渐减少。

- 氧气是燃烧的必要条件之一。
- 当氧气浓度降低到一定程度时，蜡烛就无法继续燃烧了。

第四步：二氧化碳和其他气体的积累

除了氧气的减少，燃烧还会产生其他气体，比如：

- 二氧化碳 (CO_2)
- 水蒸气 (H_2O)

这些气体在密闭空间中会逐渐增加，进一步稀释氧气的浓度，导致燃烧更难维持。

第五步：总结为什么蜡烛会熄灭

1. **氧气被逐渐消耗**，无法维持燃烧所需的浓度；
2. **二氧化碳等气体积累**，进一步抑制燃烧；
3. **没有外部空气补充**，无法恢复氧气浓度。

第六步：要让蜡烛持续燃烧需要什么条件？

1. **有充足的氧气供应**（即房间不是完全密封的，或者有通风系统）；
2. **保持适当的温度**；
3. **没有干扰燃烧的物质**；
4. **有稳定的点火源**。

Token使用：782

优势：

- 理论背景完整
- 逐步分解分析
- 条件列举全面

💡

结果分析

准确率提升分析

提升原因分析

1. 推理过程显式化

- 无CoT模式：模型直接输出答案，缺乏推理过程
- 有CoT模式：强制模型展示中间步骤，减少推理跳跃


2. 错误检测能力增强

- 无CoT模式：错误难以自我发现和纠正
- 有CoT模式：分步推理使错误更容易在中间步骤被发现

3. 复杂问题分解

- 无CoT模式：复杂问题可能导致输出混乱或截断
- 有CoT模式：将复杂问题分解为可管理的子问题

性能提升分布



关键观察：

- 常识推理类提升最大：从42.86%提升到100%
- 数学计算类提升最小：从71.43%提升到85.71%
- 说明CoT在需要多步整合的推理任务中效果更显著

Token成本分析

成本增长分析

Token使用	无CoT	有CoT	增长倍数
数学计算	146	566	3.88x
逻辑推理	155	671	4.33x
常识推理	127	802	6.31x
整体平均	143	680	4.76x

成本效益分析

准确率增长 vs Token增长：

- 数学计算：准确率+14.28%，Token+3.88x → 效益比： **3.68%/x**
- 逻辑推理：准确率+28.57%，Token+4.33x → 效益比： **6.60%/x**
- 常识推理：准确率+57.14%，Token+6.31x → 效益比： **9.06%/x**

结论：常识推理类的成本效益最高

失败案例分析

仍答错的题目（即使使用CoT）

题目ID: 4 - 逆运算问题

- 无CoT：❌ 错误（输出被截断）
- 有CoT：❌ 错误（最终答案计算错误： $11/3 \approx 3.67$ ，但正确答案是11/3）

分析：即使是CoT模式，模型在复杂逆运算问题上仍存在困难

题目ID: 11 - 家庭成员推理

无CoT: ❌ 错误 (推理不完整)
有CoT: ❌ 错误 (信息整合错误)

分析: 需要整合多个信息源的复杂推理问题仍具挑战性

结论与建议

主要结论

1. CoT技术有效性验证

✅ CoT显著提升模型推理能力

- 整体准确率从57.14%提升到90.48%
- 相对提升幅度达58.3%
- 在常识推理类题目中效果最显著

2. 性能提升具有选择性

✅ 不同类型题目提升幅度不同

- 常识推理类: +57.14% (提升最大)
- 逻辑推理类: +28.57% (中等提升)
- 数学计算类: +14.28% (提升较小)

3. Token成本显著增加

✅ 准确率提升伴随Token成本增加

- 总Token消耗增长376.37%
- 平均每题Token从143增长到680
- 常识推理类Token增长最大 (6.31x)

实践建议

1. 使用场景建议

强烈推荐使用CoT的场景:

-  常识推理和因果分析任务
-  需要详细解释的咨询场景
-  复杂逻辑推理问题
-  需要审计和验证的应用

可以考虑不使用CoT的场景：

-  简单数学计算（Token成本高但提升有限）
-  对延迟敏感的实时应用
-  Token预算受限的场景

2. 参数调优建议

输出长度控制：

```
# 推荐配置
MAX_TOKENS_WITHOUT_COT = 100      # 强制简洁
MAX_TOKENS_WITH_COT = 2000        # 允许详细推理
```

温度参数设置：

```
# 推荐配置
TEMPERATURE = 0.0 # 确保推理稳定性
```

3. 提示词优化建议

当前使用的CoT提示词：

请一步步详细思考，展示你的完整推理过程。要求：

1. 分步骤分析问题
2. 说明每个步骤的理由
3. 最后给出明确的答案

优化方向：

- 增加具体推理模板
- 添加自我验证要求
- 强调错误检查步骤

未来研究方向

1. 实验扩展

题目类型扩展：

- ☐ 添加更多应用型推理题
- ☐ 增加跨学科综合推理题
- ☐ 测试更长推理链的情况

模型对比实验：

- ☐ 不同模型CoT效果对比
- ☐ 模型规模对CoT效果的影响
- ☐ 多语言CoT效果差异

2. 技术优化

自适应CoT：

- ☐ 根据题目难度自动调整CoT强度
- ☐ 动态Token预算分配
- ☐ CoT效果实时评估

混合策略：

- ☐ CoT + Self-Consistency组合
- ☐ 分级CoT策略（部分题目使用CoT）
- ☐ CoT与Few-Shot结合

3. 应用集成

生产环境部署：

- ☐ 实现CoT效果监控
- ☐ 建立成本效益评估体系
- ☐ 开发CoT质量自动化检测

用户体验优化：

- ☐ 推理过程可视化展示
- ☐ 允许用户选择CoT模式
- ☐ 提供推理质量反馈机制

附录

A. 实验数据文件

主要结果文件：

- experiments/cot_experiment_improved_results_20260608_144524.json

数据格式：

```
{
  "experiment_info": {...},
  "analysis": {...},
  "detailed_results": [
    {
      "question_id": 1,
      "category": "数学计算",
      "question": "...",
      "without_cot": {...},
      "with_cot": {...}
    }
  ]
}
```

B. 相关代码文件

实验脚本：

- CoT/cot_experiment_improved.py - 改进版实验脚本
- CoT/cot_experiment.py - 原始实验脚本

C. 参考文献

核心论文：

1. Wei, J., et al. (2022). "Chain-of-Thought Prompting Elicits Reasoning in Large Language Models." *NeurIPS*.
2. Kojima, T., et al. (2022). "Large Language Models are Zero-Shot Reasoners." *NeurIPS*.

3. Wang, Y., et al. (2023). "Self-Consistency Improves Chain of Thought Reasoning in Language Models." *arXiv*.

相关文档：

- CoT/CoT_Papers_Abstract_Official.md - 论文摘要合集
- CoT/README.md - 项目说明文档

D. 术语表

术语	定义
CoT	Chain of Thought, 思维链提示技术
Zero-Shot CoT	零样本思维链, 无需示例即可触发
Few-Shot CoT	少样本思维链, 需要提供示例
Self-Consistency	自洽性, 多次采样取最一致答案
Temperature	温度参数, 控制模型输出的随机性
Token	文本的基本单位, 模型处理的最小单元

 报告总结

本测试报告通过21道题目的对照实验，系统验证了Chain of Thought技术对大语言模型推理能力的显著提升作用。实验结果表明：

- ✅ CoT技术能够显著提升推理准确率（从57.14%到90.48%）
- ✅ 在常识推理和逻辑推理类题目中效果最为明显
- ✅ Token成本增加约3.8倍，但准确率提升幅度更大
- ✅ 为项目中的thinking mode功能提供了实验依据

本报告的发现为CoT技术的实际应用提供了重要参考，特别是在需要高质量推理的场景中，CoT技术值得推荐使用。

报告编制：AI Chat Tool 项目组

技术审核：CoT 实验小组

文档版本：1.0

最后更新：2026年6月12日

本报告基于真实实验数据编制，所有实验结果可复现。如有疑问或需要进一步信息，请参考实验数据文件或联系项目组。